

Proyecto 2
Sistema de Recomendación de Películas
FASE 1 — Diseño del Algoritmo

Integrante 1:	Cristopher Chávez
Integrante 2:	Juan Pablo Flores
Integrante 3:	Esteban Sánchez
Integrante 4:	Javier Sánchez
Repositorio GitHub:	https://github.com/Crrrris13/Proyecto2-RecommendacionPelículas
Fecha de entrega:	06/05/2026

Sección 1 — Investigación de Algoritmos de Recomendación

1.1 ¿Qué es un sistema de recomendación?

Un sistema de recomendación es un sistema de IA que utiliza grandes cantidades de datos y algoritmos de Machine Learning para poder analizar el comportamiento e historial de interacciones de los usuarios para así poder predecir y sugerir contenido que sea relevante para cada una de las personas. Es un filtro inteligente que reduce la sobrecarga de información y ayuda al usuario a poder encontrar sus intereses (Caballar y Stryker, 2025).

Antes de que esto existiera, las plataformas mostraban listas genéricas de contenido popular, como los son los más vendidos, los más vistos, los mejor calificados, etc..., para todos los usuarios, lo que no hacía esta una experiencia personalizada. Esta estrategia funciona en ciertos contextos pero no aprovecha ese factor individual personalizado que existe hoy en día. Los sistemas de recomendación cambiaron al mercado ya que estos algoritmos sirvieron para poder aprender los gustos individuales de cada uno de los usuarios y así poder ofrecer sugerencias distintas para cada persona (Caballar y Stryker, 2025).

Para poder realizar esto, los sistemas recopilan dos tipos de datos. Los datos explícitos son lo que el usuario proporciona de forma voluntaria como calificaciones, reseñas, likes, entre otros. Los datos implícitos son aquellos que se obtienen por medio del comportamiento del usuario sin que este tenga que hacer nada extra como por ejemplo el historial de películas, el tiempo en una página, los clicks o búsquedas realizadas. Con estos datos, se puede construir un algoritmo para cada usuario que ofrezca recomendaciones más acertadas a lo que le gusta (Zaffaroni, 2025).

1.2 Algoritmos de recomendación existentes

Existen distintos enfoques para poder construir un sistema de recomendación. Cada uno de estos tienen una lógica distinta que ayuda a decidir que se le sugiere al usuario

Filtrado Colaborativo

Este es uno de los algoritmos más utilizados en sistemas de recomendación. Su idea base es que los usuarios con gustos similares en el pasado probablemente tengan gustos similares en el futuro (Caballar y Stryker, 2025).

La estructura de datos central de este algoritmo es la matriz usuario-ítem: una tabla donde las filas representan usuarios, las columnas representan ítems y cada celda contiene la calificación que el usuario le da a ese ítem. El problema de esta matriz es que es dispersa, hay muchas celdas vacías, porque es imposible que un usuario haya visto todas las películas que están disponibles. El objetivo del algoritmo es rellenar estos espacios, prediciendo la calificación que el usuario le daría a un ítem que aún no ha visto para recomendarla (Na8, s.f.).

Esta estructura puede usar un filtro basado en usuario el cual identifica que otros usuarios tienen preferencias similares al usuario objetivo y así recomendar ítems que esos usuarios similares ya calificaron positivamente pero que el usuario aún no ha visto. Además está el filtrado basado en ítem que calcula la similitud entre los ítems, basándose en cómo la calificaron los usuarios. Si muchos usuarios probaron un ítem A y un ítem B y le dieron una calificación positiva, el sistema considera que A y B son similares y las recomienda juntas (Na8, s.f.).

La debilidad de este es el cold start problem, el cual consiste en que un usuario completamente nuevo no tiene ninguna interacción, el sistema no tiene datos suficientes para encontrar usuarios similares y por ende no puede generar las mejores recomendaciones (Shokrzadeh et al., 2023).

Filtrado por contenido

El filtrado por contenido analiza las características propias para cada ítem para poder encontrar similitudes entre ellos. Si a un usuario le gustó una película, el sistema buscará otras películas con atributos similares como actores, directores, género, etc. (Caballar y Stryker, 2025).

Lo bueno de este filtrado es que no depende del comportamiento de otros usuarios para poder dar una recomendación, por lo que no sufre del cold start problem del filtrado colaborativo. Puede generar recomendaciones desde el primer momento en el que un usuario expresa una preferencia, incluso antes de que este tenga un historial extenso (Na8, s.f.).

El problema del cual sufre este filtrado es que tiende a recomendar contenido muy similar a lo que el usuario ya ha visto, lo cual puede generar una experiencia un poco repetitiva y reduce la posibilidad de poder descubrir contenido nuevo y encontrar nuevos gustos (Caballar y Stryker, 2025).

Sistema híbrido

Un sistema híbrido combina los filtros colaborativo y por contenido para poder aprovechar las ventajas de ambos enfoques y así poder compensar sus debilidades. Se integra la información de usuarios similares y sobre características de los ítems al mismo tiempo, logrando recomendaciones más precisas y variadas (Zaffaroni, 2025).

Las plataformas de streaming más grandes usan este sistema por su facilidad de analizar al usuario. Netflix por ejemplo combina la similitud entre usuarios con el análisis de características del contenido como género, duración y elenco para poder decidir qué recomendar a cada uno (Caballar y Stryker, 2025).

Filtrado contextual

El filtrado contextual no es tan conocido como los otros pero también tiene un enfoque diferente. Este incorpora información del contexto del momento en que el usuario está usando la plataforma para recomendar. Variables como el dispositivo que se utiliza, el horario, la ubicación o la secuencia de acciones recientes del usuario se toman en cuenta para poder personalizar aún más recomendaciones (NVIDIA, s.f.).

Netflix utiliza este enfoque tomando en cuenta el país, el dispositivo, la fecha y la hora en que el usuario vio una película para poder predecir lo que querrá ver a continuación. Esto ayuda a que la recomendación se adapte no solo a los gustos sino a la ocasión (NVIDIA, s.f.).

1.3 ¿Por qué usar una base de datos de grafos para recomendaciones?

Cuando se quiere almacenar datos en un sistema, la primera idea es la de una base de datos relacional tradicional. En este modelo, los datos se organizan en tablas con temas como usuarios, películas, géneros y calificaciones. Para poder encontrar recomendaciones, se tendría que cruzar todas estas tablas por medio de operaciones JOIN. El problema es que lo importante de un sistema de recomendación no son los datos en sí, sino las relaciones que surgen entre ellos. En una base de datos relacional, responder preguntas como qué películas comparten género o qué usuarios tienen gustos similares se vuelve lento y costoso para la computadora ya que las relaciones no están almacenadas directamente sino que se calculan en cada consulta (Shokrzadeh et al., 2023).

Los grafos son la solución natural a este problema. Un grafo de conocimientos resuelve este problema porque las relaciones no se calculan al momento de la consulta sino que están almacenadas, por lo que recorrer conexiones entre los nodos es rápido (Vengurlekar, 2023).

La estructura básica de un grafo consiste en tres componentes. Los nodos, los cuales representan una entrada del sistema, las relaciones o aristas las cuales representan las conexiones entre las entidades. Por último las propiedades, que son atributos adicionales que pueden tener tanto los nodos como las relaciones (Vengurlekar, 2023).

Una de las ventajas más poderosas de los grafos es la capacidad de descubrir relaciones indirectas entre los nodos, conocidos como vecinos de múltiples saltos. Esto es fundamental para generar recomendaciones más variadas. Esto ayuda a resolver el cold start problem ya que los usuarios nuevos se pueden conectar a sus géneros o directores favoritos (Shokrzadeh et al., 2023).

Neo4j es la base de datos de grafos más utilizada del mundo. Es de código abierto y está diseñada para almacenar y consultar datos en forma de gráficos de conocimiento. Este usa el Property Graph Model, que es la estructura de grafos. Su lenguaje de consulta se llama Cypher, el cual cumple el mismo rol que un SQL en bases de datos relacionales pero está diseñado para trabajar con grafos (Vengurlekar, 2023).

1.4 Algoritmo seleccionado para este proyecto

Se utilizará un sistema híbrido basado en grafos, combinando filtrado colaborativo y filtrado por contenido (Caballar y Stryker, 2025).

Justificación

Este enfoque permite aprovechar las ventajas de ambos algoritmos. Por un lado, el filtrado colaborativo permite identificar usuarios con gustos similares y recomendar películas que estos han disfrutado. Por otro lado, el filtrado por contenido permite analizar las características propias de las películas, como género, actores o director, para recomendar contenido similar (Na8, s.f.).

El uso de grafos permite representar de forma eficiente las relaciones entre usuarios, películas y atributos, facilitando el recorrido de conexiones directas e indirectas. Esto permite generar recomendaciones más precisas y variadas (Vengurlekar, 2023).

Además, este enfoque ayuda a mitigar el problema de "cold start", ya que incluso si un usuario nuevo no tiene historial, puede ser conectado a géneros o preferencias iniciales dentro del grafo (Shokrzadeh et al., 2023).

Sección 2 — Design Thinking

2.1 Empatía — Entrevistas con usuarios

Resumen de entrevista — Usuario 1:

Perfil:

Estudiante universitario que utiliza múltiples plataformas de streaming

Respuestas y observaciones clave:

- Utiliza las recomendaciones ocasionalmente
- Tarda entre 10 y 15 minutos en decidir qué ver
- Se basa principalmente en géneros y actores
- Considera que las recomendaciones son medianamente útiles
- Se frustra por la gran cantidad de opciones que ofrecen
- Le gustaría que las recomendaciones fueran más personalizadas

Resumen de entrevista — Usuario 2:

Perfil:

Usuario frecuente de plataformas de streaming que consume contenido de forma regular.

Respuestas y observaciones clave:

- Rara vez utiliza las recomendaciones que ofrecen las plataformas
- Puede tardar más de 30 minutos en decidir qué ver
- Se guía por opiniones de amigos y redes sociales
- Indica que las recomendaciones son poco precisas
- Se frustra cuando no encuentra contenido interesante fácilmente
- Prefiere recomendaciones más precisas que variedad

Resumen de entrevista - Usuario 3:

Perfil:

Usuario que consume contenido en varias plataformas y busca facilidad en la elección.

Respuestas y observaciones clave:

- Utiliza recomendaciones algunas veces
- Tarda entre 5 y 10 minutos en elegir contenido
- Se basa en género y calificaciones externas
- Considera que las recomendaciones actuales podrían mejorar
- Se frustra cuando el contenido sugerido no está disponible en su plataforma
- Valora sistemas simples y fáciles de usar con recomendaciones claras

Patrones identificados entre los entrevistados:

- Los usuarios tienen acceso a múltiples plataformas, pero aún así presentan dificultad para decidir qué ver.

- Existe una baja confianza en las recomendaciones actuales, ya que muchos usuarios solo las utilizan ocasionalmente.
- El proceso de selección puede tomar varios minutos, lo que indica ineficiencia en la experiencia.
- Los factores más influyentes son el género, actores y opiniones de amigos.
- Las principales frustraciones incluyen no encontrar contenido interesante, exceso de opciones y recomendaciones poco relevantes.
- Los usuarios desean recomendaciones más personalizadas, pero también valoran descubrir contenido nuevo.
- La influencia social, como amigos o redes sociales, juega un papel importante al momento de tomar la decisión.

2.2 Definición del problema

Enunciado del problema:

Los usuarios tienen dificultades para encontrar películas que les interesen de manera rápida y eficiente, debido a la baja precisión de las recomendaciones actuales y la gran cantidad de opciones distribuidas en múltiples plataformas.

Point of View (POV):

El usuario que consume contenido en múltiples plataformas necesita recomendaciones personalizadas y confiables porque actualmente pierde tiempo decidiendo qué ver y no confía completamente en las sugerencias existentes.

¿Quién es el usuario objetivo de tu sistema?

Usuarios de todas las edades que consumen contenido en múltiples plataformas de streaming y buscan recomendaciones rápidas, personalizadas y confiables para optimizar su tiempo de decisión.

2.3 Ideación

Lluvia de ideas (mínimo 5 formas diferentes de recomendar):

Idea 1:

Recomendaciones basadas en usuarios con gustos similares.

Idea 2:

Recomendaciones basadas en contenido, analizando géneros, actores y directores de películas previamente vistas.

Idea 3:

Recomendaciones basadas en tendencias en el momento.

Idea 4:

Recomendaciones basadas en parecido con contenido visualizado y que hayan obtenido altas calificaciones.

Idea 5:

Recomendaciones basadas en contexto (Dando distintas recomendaciones de día que de noche).

Idea seleccionada:

¿Cuál eligieron y por qué es la mejor para resolver el problema identificado?

Se escogió una combinación de recomendaciones de usuarios parecidos con el análisis del contenido específico. Esto no solo permite una mayor precisión en las recomendaciones, pero también flexibilidad en el contenido que puede estar presente en la recomendación.

¿Qué datos considerará el sistema para recomendar?

Género de la película (acción, comedia, drama, etc.)

Director

Actores

Calificación / rating

Año de lanzamiento

Historial de películas vistas por el usuario

Películas marcadas como favoritas

2.4 Prototipo de baja fidelidad

Pantalla 1

☰ Mis Preferencias

1. ¿Qué géneros te gustan?

☐ Acción

☐ Comedia

☐ Drama

☐ Ciencia Ficción

☐ Terror

☐ Animación

☐ Romance

☐ Otro: _____

2. Actores o directores favoritos

Nombre de actor o director...

3. ¿Qué tipo de recomendación prefieres?

☐ Más precisa (basada en tus gustos)

☐ Más variada (cosas nuevas)

Continuar →

Pantalla 2

☰ Recomendaciones para ti 🔍

Basada en tus gustos y actividad

Interstellar (2014)
★ 8.6/10
Ciencia Ficción, Drama
Christopher Nolan.

Inception (2010)
★ 8.8/10
Ciencia Ficción, acción
Similar a Interstellar

The Martian (2015)
★ 8.0/10
Ciencia Ficción, Aventura
Buenas reviews

Ver más ↓

Pantalla 3

☰ Detalles ←

Interstellar (2014)
Ciencia Ficción, Drama
★ 8.6/10

¿Te gustó esta recomendación?

Me gustó No me gustó

Califica (opcional)

☆☆☆☆

¿Por qué? (opcional)

Escribe tu opinión...

Guardar

Descripción del flujo del prototipo (qué hace el usuario paso a paso):

El usuario inicia en la pantalla principal del sistema, donde se le solicita ingresar sus preferencias personales. En esta etapa, selecciona los géneros de películas que le interesan, puede ingresar actores o directores favoritos y define si prefiere recomendaciones más precisas o más variadas.

Una vez completadas sus preferencias, el usuario presiona el botón de continuar. El sistema procesa esta información y lo dirige a la pantalla de recomendaciones.

En la pantalla de recomendaciones, el usuario visualiza una lista de películas sugeridas. Cada recomendación incluye información relevante como el título, calificación y una breve explicación de por qué fue recomendada.

El usuario puede explorar las distintas opciones y seleccionar una película para ver más detalles o simplemente evaluar las recomendaciones mostradas.

Posteriormente, el usuario pasa a una sección de feedback, donde puede indicar si una recomendación le gustó o no, así como asignar una calificación o agregar un comentario opcional.

Finalmente, esta retroalimentación es utilizada por el sistema para ajustar futuras recomendaciones, mejorando la personalización y precisión del algoritmo en interacciones posteriores.

2.5 Testing del prototipo

Feedback — Usuario 1:

Indica que le gusta la interfaz mostrada en el prototipo, que es amigable a la vista y es sencilla de entender. También indica que no realiza ningún cambio en el diseño de la app.

Feedback — Usuario 2:

Indica que la interfaz de inicio es amigable y sencilla de comprender, que para él es una aplicación que definitivamente usaría para ver recomendaciones de películas. Pero que en la pantalla de recomendación de películas agregaría el director de cada película a los atributos que se muestran en la aplicación.

Feedback — Usuario 3:

Le gusta que la interfaz sea amigable con el cliente, indica que se ve sencilla de usar para todo tipo de usuario, más al momento de marcar los gustos del usuario, ver las películas que pueden ser de su agrado, ver calificaciones. Indica que un cambio o algo que se debería de agregar es mostrar en qué plataforma de streaming se encuentra disponible la película en cuestión.

Ajustes realizados al prototipo luego del testing:

¿Qué cambiaron en base al feedback recibido?

Agregamos en la sección de la película en que plataforma de streaming se encuentra disponible la película en cuestión, también el que aparezcan todos los atributos en la descripción de la película, incluyendo director, actores, géneros, etc.

The image shows four hand-drawn mobile app screens:

- Inicio de Sesión (Login):** Features a large "Log In" title, input fields for "Usuario" and "Contraseña", a checkbox for "Recordar usuario", and an "Ingresar" button.
- Mis Preferencias (My Preferences):** Contains three sections: 1. "¿Qué géneros te gustan?" with checkboxes for Acción, Comedia, Drama, Ciencia Ficción, Terror, Animación, Romance, and Otro. 2. "Actores o directores favoritos" with a text input field. 3. "¿Qué tipo de recomendación prefieres?" with radio buttons for "Más precisa" and "Más variada". A "Guardar" button is at the bottom.
- Recomendaciones para ti (Recommendations for you):** Titled "Basado en tus gustos y actividad", it lists three movies: "Interstellar (2014)", "Inception (2010)", and "The Martian (2015)", each with a rating and genres. A "Ver más" button is at the bottom.
- Detalles (Details):** Shows details for "Interstellar (2014)", including its rating and genres. It includes a "¿Te gustó esta recomendación?" section with "Me gusta" and "No me gusta" buttons, a "Califica (opcional)" section with five stars, and a "Disponible en" section with logos for Netflix (N) and Apple TV (Apple logo), followed by a "Guardar" button.

Sección 3 — Pseudocódigo del Algoritmo

3.1 Entradas del algoritmo

¿Qué datos recibe el algoritmo como entrada?

ID o perfil del usuario

Historial de películas vistas

Géneros favoritos

Calificaciones dadas por el usuario

3.2 Salidas del algoritmo

¿Qué devuelve el algoritmo?

Una lista de películas recomendadas incluyendo: Título de la película, puntaje dado de relevancia y la razón de la recomendación.

3.3 Pseudocódigo

```

FUNCIÓN recomendar_peliculas(usuario_id):

    // Paso 1: Obtener nodo usuario del grafo
    usuario ← buscar_usuario(usuario_id)
    peliculas_vistas ← obtener_peliculas_vistas(usuario)

    recomendaciones ← diccionario (pelicula → puntaje)

    // Paso 2: Filtrado colaborativo (usuarios similares en el grafo)
    usuarios_similares ← buscar_usuarios_similares(usuario)

    FOR cada u EN usuarios_similares HACER:
        peliculas_u ← obtener_peliculas_gustadas(u)

        FOR cada pelicula EN peliculas_u HACER:
            IF pelicula NO está en peliculas_vistas ENTONCES:
                recomendaciones[pelicula] += 1
            FIN IF
        FIN FOR
    FIN FOR

    // Paso 3: Filtrado por contenido (recorriendo relaciones del grafo)
    FOR cada pelicula_vista EN peliculas_vistas HACER:

        generos ← obtener_generos(pelicula_vista)
        actores ← obtener_actores(pelicula_vista)
        director ← obtener_director(pelicula_vista)

        peliculas_similares ← buscar_por_relaciones(generos, actores, director)

        FOR cada pelicula EN peliculas_similares HACER:
            IF pelicula NO está en peliculas_vistas ENTONCES:
                recomendaciones[pelicula] += 2
            FIN IF
        FIN FOR

        // Relaciones directas SIMILAR_A
        peliculas_relacionadas ← obtener_similares(pelicula_vista)

        FOR cada pelicula EN peliculas_relacionadas HACER:
            IF pelicula NO está en peliculas_vistas ENTONCES:
                recomendaciones[pelicula] += 3
            FIN IF
    
```

```

        FIN FOR

    FIN FOR

    // Paso 4: Ordenar por relevancia
                                lista_recomendaciones ←
ordenar_por_puntaje(recomendaciones)

    // Paso 5: Seleccionar top N
    RETORNAR primeros 10 elementos de lista_recomendaciones

FIN FUNCIÓN

```

3.4 ¿Cómo usa el grafo el algoritmo?

El algoritmo utiliza el grafo recorriendo las relaciones entre los nodos de usuario, película y sus atributos.

Primero, para el filtrado colaborativo, parte del nodo del usuario y sigue las relaciones de LE_GUSTO hacia las películas que ha disfrutado. Luego, busca otros usuarios que también estén conectados a esas mismas películas. Estos usuarios se consideran similares. A partir de ellos, el algoritmo recorre sus conexiones hacia otras películas que les gustaron y que el usuario original aún no ha visto, generando recomendaciones por similitud.

Luego, el algoritmo toma las películas vistas por el usuario y recorre sus relaciones hacia nodos de género, actor y director. Desde esos nodos, busca otras películas conectadas que comparten esas características, generando recomendaciones basadas en similitud de contenido. Finalmente, el sistema combina ambos recorridos dentro del grafo para producir recomendaciones más completas, aprovechando tanto las conexiones entre usuarios como las características de las películas.

Sección 4 — Diseño de la Base de Datos en Grafos

4.1 Nodos (tipos de entidades)


Tipo de nodo	Propiedades	Ejemplo
Usuario	id, nombre, edad, géneros favoritos	Ana García · U001
Película	id, título, año, rating	Interstellar (2014)
Género	nombre	Ciencia Ficción
Actor	id, nombre, nacionalidad	Matthew McConaughey

Director	id, nombre, nacionalidad	Christopher Nolan
----------	--------------------------	-------------------

4.2 Relaciones (aristas entre nodos)

Nombre relación	Desde	Hacia	Propiedad (si aplica)
VIO	Usuario	Película	fecha
LE_GUSTO	Usuario	Película	puntaje (1-5)
ES_DE_GENERO	Película	Género	—
ACTUO_EN	Actor	Película	—
DIRIGIÓ	Director	Película	—

4.3 Diagrama del grafo



4.4 ¿Cómo permite este grafo hacer recomendaciones?

El grafo permite generar recomendaciones viendo las conexiones entre sus nodos, partiendo siempre desde el usuario que hace la consulta.

Para el filtrado colaborativo, el sistema parte de Ana García y sigue sus conexiones LE_GUSTO para ver qué películas disfrutó. Luego busca otros usuarios que hayan disfrutado esas mismas películas, identificándolos como personas con gustos parecidos. Con eso recoge las películas que esos usuarios similares valoraron bien pero que Ana todavía no ha visto y las convierte en recomendaciones.

Para el filtrado por contenido, el sistema toma una película que Ana ya vio como Interstellar, y explora sus características: a qué géneros pertenecen, quién la dirigió y quiénes actuaron en ella. Con esa información, busca otras películas en el grafo que compartan esas mismas características y las sugiere como opciones relevantes.

Por ejemplo un caso ficticio es que Ana García entra al sistema y el algoritmo detecta que le encantó Interstellar. Desde ahí sigue la conexión hacia Christopher Nolan como director y descubre que también dirigió Inception, que Ana no ha visto. Al mismo tiempo encuentra a Carlos López, otro usuario al que también le gustó Interstellar y nota que Carlos valoró muy bien The Dark Knight. Como Ana tampoco la ha visto el sistema la incluye en la lista. Al final combina ambos caminos el de las características de la película y el de usuarios parecidos para entregar las recomendaciones.

Anexos — Evidencia de usuarios

Link a las entrevistas

[Entrevistas](#)

Referencias

Gómez-Uribe, C. A., & Hunt, N. (2015). The Netflix recommender system: Algorithms, business value, and innovation. *ACM Transactions on Management Information Systems*, 6(4), 1–19. <https://dl.acm.org/doi/10.1145/2843948>

Neo4j, Inc. (s.f.). *What is a graph database?* <https://neo4j.com/docs/getting-started/graph-database/>

IBM. (s.f.). *What is a recommendation engine?* <https://www.ibm.com/think/topics/recommendation-engine>

Netflix Technology Blog. (s.f.). *Machine learning at Netflix.* <https://netflixtechblog.com/democratizing-machine-learning-at-netflix-building-the-model-lifecycle-graph-5cc6d5828bb1>

Caballar, R. D. y Stryker, C. (2025). *Recommendation engine.* IBM Think. <https://www.ibm.com/es-es/think/topics/recommendation-engine>

Na8. (s.f.). *Sistemas de recomendación.* Aprende Machine Learning. <https://www.aprendemachinelearning.com/sistemas-de-recomendacion/>

NVIDIA. (s.f.). *Recommendation system.* NVIDIA Glossary. <https://www.nvidia.com/en-us/glossary/recommendation-system/>

Shokrzadeh, Z., Feizi-Derakhshi, M. R., Balafar, M. A. y Bagherzadeh Mohasefi, J. (2023). *Knowledge graph-based recommendation system enhanced by neural collaborative filtering and knowledge graph embedding.* Ain Shams Engineering Journal, 14(8), 102263. <https://doi.org/10.1016/j.asej.2023.102263>

Vengurlekar, S. (2023). *Building a recommendation engine using Neo4j hands-on — Part 1*. Neo4j Developer Blog.
<https://neo4j.com/blog/developer/recommendation-engine-hands-on-1/>

Zaffaroni, A. (2025). *Algoritmos de recomendación: tipos, aplicaciones y su impacto en la experiencia del usuario*. Innovación Digital 360.
<https://www.innovaciondigital360.com/i-a/algoritmos-de-recomendacion-tipos-aplicaciones-y-su-impacto-en-la-experiencia-del-usuario/>